



Préparation de données

Matériels nécessaires pour le TP

- Une distribution Python : **Anaconda** (Python + Jupyter Notebook)
<https://jupyter.readthedocs.io/en/latest/install.html>
- Une bibliothèque du data mining : **scikit-learn**

scikit-learn est une bibliothèque Python à code source ouvert (open source) dotée d'outils puissants pour l'analyse et l'exploration de données. Elle est disponible sous licence BSD et est construite sur les bibliothèques d'apprentissage automatique :

<http://cedric.cnam.fr/vertigo/Cours/ml/installationScikitLearn.html>

- ✓ **NumPy** : un package nécessaire pour le calcul scientifique. Il comprend une structure incroyablement polyvalente pour manipuler les tableaux multidimensionnels, qui sont le principal format de données utilisé par scikit-learn pour les données en entrée.
- ✓ **SciPy** : une collection d'outils pour les statistiques en Python.
- ✓ **Matplotlib** : une bibliothèque destinée à tracer et visualiser des données sous formes de graphiques.
- ✓ **Pandas** : une bibliothèque écrite pour le langage de programmation Python permettant la manipulation et l'analyse des données. Elle propose en particulier des structures de données et des opérations de manipulation de tableaux numériques et de séries temporelles.

Commencer avec scikit-learn

- *Chargement d'un jeu de données (dataset)*

```
from sklearn import datasets
digits=datasets.load_digits()
boston=datasets.load_boston()
```

- *Prétraitements de données* : package sklearn.preprocessing
 - ✓ *Standardisation* : scale(X) , MinMaxScaler() , ...
 - ✓ *Normalisation* : normalize(X)
 - ✓ *Codage des attributs catégoriels* : OrdinalEncoder
 - ✓ *Discretisation* : KBinsDiscretizer
 - ✓ *Binarisation* : Binarizer

Exercice 01

Les données avec lesquelles nous allons travailler dans cet exercice constituent un très petit ensemble de données immobilières.

Le tableau ci-après montre ce petit ensemble de données composé de quatre colonnes (attributs) qui sont :

ST_NUM	ST_NAME	NUM BEDROOMS	OWN OCCUPIED
104	PUTNAM	3	Y
197	LEXINGTON	3	N
	LEXINGTON	n/a	N
201	BERKELEY	1	12
203	BERKELEY	3	Y
207	BERKELEY	NA	Y
NA	WASHINGTON	2	
213	TREMONT	--	Y
215	TREMONT	Na	Y

ST_NUM: Street Number

ST_NAME: Street Name

NUM_BEDROOMS: Nombre de chambres

OWN_OCCUPIED: Le propriétaire de la résidence est-il occupé ou non?

Travail demandé :

- ✓ Transformer le tableau ci-dessus en fichier Immo.csv.
- ✓ Afficher les premières lignes du fichier Immo.csv en utilisant la méthode **head ()** de pandas.
- ✓ La méthode **isnull()** de pandas nous permet de détecter la présence des valeurs manquantes pour chaque attribut de l'ensemble de données.
 - Examiner le nombre total de valeurs manquantes.
 - Proposer une première solution avec pandas
 - Proposer une deuxième solution avec scikit-learn.

Exercice 02

Objectif visé

Dans cet exercice de TP, vous apprendrez les bases et la mise en œuvre de plusieurs techniques de préparation de données suivantes :

- Traitement des entrées incorrectes
- Traitement des données manquantes
- Encodage des étiquettes catégoriques

- Gestion des données aberrantes
- Transformation
- Standardisation et Normalisation
- Conversion des types de colonnes
- Sélection d'attributs en calculant les corrélations des attributs (Coefficient de corrélation de Pearson pour les attributs numériques, Test de Chi2 pour les attributs catégoriques)

Data

Le jeu de données ***Loan-Approval*** (Fichier texte ci-joint) est utilisé dans cet exercice.

Nous utiliserons des données fictives de demandeurs de prêt qui contiennent **600** observations et **14** variables, comme décrit ci-dessous :

1. ***Loan_ID*** : Identificateur du demandeur
2. ***Gender*** : que le demandeur soit une femme 'Female' ou un homme 'Male'
3. ***Marital Status*** : le demandeur est marié 'Yes' ou non 'No'
4. ***Dependents*** : nombre de personnes à charge réclamées par le demandeur
5. ***Education*** : indique si le candidat est diplômé 'Graduate' ou non 'Not Graduate'
6. ***Self_Employed*** : indique si le demandeur travail chez un employeur 'Yes' ou non 'No'
7. ***ApplicantIncome*** : revenu annuel du demandeur
8. ***CoapplicantIncome*** : revenu annuel du conjoint
9. ***LoanAmount*** : le montant du prêt demandé
10. ***Loan_Amount_Term*** : Durée du prêt (en mois)
11. ***Credit_History*** : Historique du crédit (0 ou 1)
12. ***Risk*** : la cote de crédit est bonne 'Yes' ou non 'No'
13. ***Property_Area*** : indique la zone de propriété du demandeur (Urban, Semiurban, Rural)
14. ***Loan-Status*** : indique si la demande de prêt a été approuvée 'Y' ou non 'N'

Le travail demandé est de :

1. Chargez le jeu de données.
2. Lire les données.
3. Comprendre les données (noms des variables, formats et types, formes, ...).
4. Divisez le jeu de données en variables d'entrée et de sortie pour l'apprentissage.
5. Appliquez les transformations de prétraitement suscitées aux variables d'entrée et résumez les données pour montrer le changement.